鸢尾花线性二分类示例：setosa 与其余类

课程设计示例文档

摘要

本文以真实的鸢尾花（Iris）数据集为例，仅使用前两个特征（萼片长、萼片宽），将 setosa 与其余两类做二分类，并构建一个简单线性分类器（Fisher 线性判别，闭式解）作为实际示例。全文聚焦“如何构建与解释一个线性分类器”，不做繁琐推导。

1 数据来源

数据取自 **UCI Machine Learning Repository** 的 Iris 数据集（R. A. Fisher, 1936），可直接从 `https://archive.ics.uci.edu/dataset/53/iris` 获取；亦可经由 scikit-learn 内置函数 `load_iris()` 载入（二者同源，数值一致）。本文示例读取本地文件 `iris.data`。

该数据集共 $n = 150$ 个样本、3 个类别（各 50 个），每条记录含 4 个特征与 1 个类别标签。本示例仅保留前两个特征：

- x_1：萼片长度（sepal length，单位 cm）；
- x_2：萼片宽度（sepal width，单位 cm）。

并将标签重编码为二值：**setosa 记为** $y = 1$，其余两类合并记为 $y = 0$。

2 模型：线性分类器

本例采用 **Fisher 线性判别（LDA）**——一种线性方法，具有闭式解，无需迭代优化。其判别函数为

$$g(\mathbf{x}) = \mathbf{w}^{\mathsf{T}}\mathbf{x} + b, \qquad \hat{y} = \begin{cases} 1 & (g(\mathbf{x}) > 0), \\ 0 & (\text{否则}), \end{cases} \tag{1}$$

其中 $\mathbf{x} = (x_1, x_2)^{\mathsf{T}}$。判别方向 $\mathbf{w}$ 与偏置 b 由训练数据闭式给出：

$$\mathbf{w} = \mathbf{S}_w^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0), \tag{2}$$

$$b = -\mathbf{w}^{\mathsf{T}}\left(\frac{\boldsymbol{\mu}_1 + \boldsymbol{\mu}_0}{2}\right), \tag{3}$$

这里 $\boldsymbol{\mu}_1, \boldsymbol{\mu}_0$ 分别为两类样本均值，$\mathbf{S}_w$ 为类内散布矩阵。决策边界即直线 $\mathbf{w}^{\mathsf{T}}\mathbf{x} + b = 0$，是一条**直线**（线性），这正是“线性方法”的含义。

3 实验设置

- **特征**：第 1、2 列（萼片长、萼片宽），未做标准化；
- **标签**：setosa $\to y=1$，其余 $\to y=0$；
- **划分**：按 7 : 3 切分训练/测试集，固定随机种子（`default_rng(42)`，等价于 `random_state=42`）以保证可复现；
- **拟合**：仅用训练集估计 $\boldsymbol{\mu}_1, \boldsymbol{\mu}_0, \mathbf{S}_w$，再作用于测试集（避免数据泄露）。

4 结果

由训练集估计得到的线性分类器参数为

$$\mathbf{w} = \begin{pmatrix} -0.0672 \\ 0.1163 \end{pmatrix}, \qquad b = 0.0150.$$

决策边界方程为

$$-0.0672\, x_1 + 0.1163\, x_2 + 0.0150 = 0, \quad \text{即} \quad x_2 \approx 0.578\, x_1 - 0.129.$$

表 1: 示例关键数值（一次确定性运行结果）

项目	数值
样本总数 n	150
setosa $(y=1)$	50
其余 $(y=0)$	100
训练样本	105 (=70%)
测试样本	45 (=30%)
w_1（萼片长系数）	−0.0672
w_2（萼片宽系数）	0.1163
截距 b	0.0150
训练准确率	98.10%
测试准确率	97.78%

图 1 给出两类样本散点与所学决策边界。可见 setosa 在“小萼片长、大萼片宽”区域聚集，被一条直线较好分开。

5 结论

在该二分类任务上，简单的线性分类器即取得约 98% 的准确率，说明仅用“萼片长、萼片宽”两维已能较好区分 setosa 与其余类。但准确率并非 100%，表明 setosa 在这两个特征上“近似”而

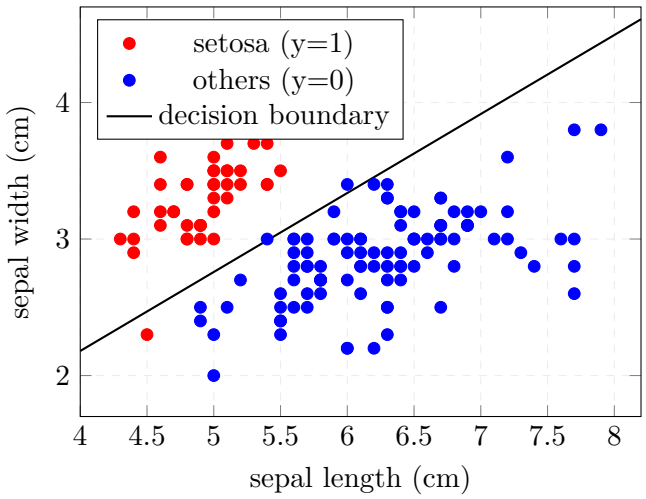


图 1: setosa 与其余类在前两个特征上的散点及线性决策边界（图形由 `iris_linear_demo.py` 生成：有 matplotlib 时为 PNG，否则为 TikZ）。

非“完全”线性可分——这是数据本身的特性，并不等于线性模型“万能”。当数据呈明显非线性边界时，应转向核方法或更复杂模型（参见课程教材第 8 章支持向量机）。

6 读者需确认的关键事项清单

1. **数据来源与版本：**本文数据来自 UCI Iris（Fisher, 1936），与 `sklearn.load_iris()` 同源；若改用 `load_iris()`，请确认其返回的特征顺序与标签编码一致（前两列为萼片长、萼片宽）。

2. **标签定义：**正类设为 setosa（$y = 1$），其余两类合并为 $y = 0$；若交换定义，判别系数符号整体取反，但决策边界不变。

3. **特征与单位：**仅使用第 1、2 列（萼片长、萼片宽，单位 cm），未做标准化；本例近似可分故可行，换用其他数据须谨慎。

4. **可复现性：**训练/测试划分由固定随机种子（`default_rng(42)`）决定；更换种子，准确率会有小幅波动，结论不变。

5. **线性可分性：**setosa 与前两维下的其余类“近似”而非“完全”线性可分（故准确率 $\approx 98\%$ 而非 100%），这是数据特性。

6. **模型假设：**本例采用 Fisher 线性判别（LDA，闭式解），属线性方法；若数据非线性可分，应改用核方法或更复杂模型（教材第 8 章 SVM）。

7. **结论边界：**高准确率来自“两维下 setosa 可较好分离”，并非模型复杂；本示例意在演示线性分类器的构建与边界，而非追求性能上限。

8. **依赖与运行**：可执行代码 `iris_linear_demo.py` 仅需 Python 3 + NumPy，无需 scikit-learn；图形优先用 matplotlib 生成 PNG，否则退回 TikZ 片段。本文档（PDF）仅作解释用途，编译需同目录的图形文件（`iris_boundary.png` 或 `iris_figure.tex`）。

7 代码说明与运行

本文档仅用于**解释代码及其运行过程**；可执行代码位于独立的 `iris_linear_demo.py`，并不嵌入本文档。相关文件如下：

- `iris_linear_demo.py`：主程序（仅依赖 NumPy；绘图可选 matplotlib）。
- `iris.data`：UCI Iris 原始数据（本地副本，亦可由 `sklearn.load_iris()` 获取）。
- `iris_linear_results.txt`：脚本运行后生成的“说明 + 数值”文本（便于查阅/保存）。
- `iris_boundary.png` 或 `iris_figure.tex`：决策边界图（二选一，由脚本生成）。

运行方式 在终端执行 `python iris_linear_demo.py`（需 Python 3 与 NumPy）。若环境中已安装 Matplotlib，脚本额外输出 `iris_boundary.png`；否则自动退化为输出 TikZ 片段 `iris_figure.tex`，供本文档绘图使用。绘图失败不影响核心数值产出（结果仍写入 txt）。

脚本流程

1. 读取本地 `iris.data`，仅取前两特征（萼片长、萼片宽），并将 setosa 标为 $y = 1$、其余类标为 $y = 0$；
2. 以固定随机种子（`default_rng(42)`）按 7 : 3 划分训练/测试集；
3. 仅用训练集，按 Fisher 线性判别（LDA）闭式解估计 $\mathbf{w}, b$（式 (2)–(3)）；
4. 在训练集与测试集上评估准确率；
5. 将说明文字与全部数值写入 `iris_linear_results.txt`，并尝试绘制决策边界。

与本文档的关系 本文档的“数据来源 / 模型 / 结果 / 结论 / 清单”等章节，正是对上述代码所实现方法及其运行结果（表 1、图 1）的解释。代码本身可独立运行，不依赖 LaTeX。

参考文献

[1] R. A. Fisher. The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2):179–188, 1936.

[2] UCI Machine Learning Repository. *Iris Data Set*. `https://archive.ics.uci.edu/dataset/53/iris`.

[3] scikit-learn developers. `sklearn.datasets.load_iris`. `https://scikit-learn.org/`.

[4]《Python 机器学习：原理与实践》第 8 章，支持向量机（线性方法与核方法的延伸参照）.